Universidad de Chile
Facultad de Ciencias Físicas y Matemáticas
Depto. de Ciencias de la Computación
CC4102 - Diseño y Análisis de Algoritmos

Tarea 3

Integrantes : Americo Ferrada
Belisario Panay
Profesor : Pablo Barcelo
Ayudantes : Claudio Torres
Jaime Salas
Auxiliar : Ariel Cáceres

Índice

1. Introducción

En el presente informe se muestra el diseño, implementación y exvaluación y comparación en la práctica de tres enfoques para encontrar una solución aproximada dle problema de Cubrimiento de Vértices Mínimo, el primero la 2-aproximación vista en clases, el segundo la heurística vista en clase auxiliar y por ultimo un tercer enfoque que utiliza ambos enfoques.

Para esta tarea se comprarán el tamaño de los resultados entregados por las tres aproximaciones antes explicados. Para esto se correran los experimentos en grafos de distintos tamaños, creando grafos de manera aleatoria con una probabilidad de que dos vertices esten conectados, para así obtener promedios confiables.

1.1. Problema a resolver

Encontrar el Cubrimiento por Vértices Mínimo es un problema np-Completo por lo que no puede ser usado en la práctica, para esto se ocupan los algoritmos aproximados que entregan una solucion a este problema con ciertas garantias (distancia máxima del optimo).

1.2. Hipótesis

En general se espera que la cantidad de vertices encontrados por los tres algoritmos, aumente en función del valor de p, esto es, mientras exista una probabilidad mayor de que una arista pertenezca al grafo, mayor será el tamaño de las soluciones.

La 2-aproximación tomará menor tiempo de ejecución que las otras dos aproximaciones, pero entregará mayor cantidad de vertices que la solución de la 2-Aproximacion mejorada.

Para el caso de la Heurística, se espera que la cantidad de vertices entregados sean dependientes de la entrada.

Por último para la 2-Aproximación mejorada, se cree que ocupando parte de los dos enfoques anteriores, entregará mejores resultados que las otras aproximaciones, aunque se espera que no se diferencie mucho de la 2-Aproximación.

2. Diseño Teórico

2.1. Estructuras y Probabilidades

En esta sección se mostrará la estructura utilizada para representar el grafo, además de la descripción de las clases utilizadas en la implementación.
Para representar el grafo, se dicidió utilizar la estructura presentada por el profesor José Fuentes, el cual representa el grafo con dos arreglos, un arreglo de aristas E_G (una lista de adyacencia), las cuales poseen una arista y otra complementaria (ej: (u,v) y (v,u)), cada arista posee un *source* o src (vertice del que proviene) y un *target* o tgt (vertice al que va), además de que cada una posee el indice de su arista complementaria (cmp). Tambien posee un arreglo de vertices V_G, donde cada vertice posee el inicio y final de donde se encuentra en la lista de aristas. Para una mayor comprensión se muestra la siguiente figura.

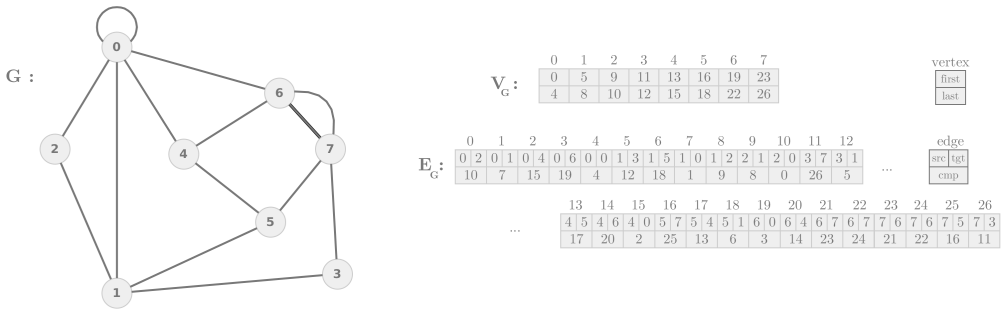

Para los experimentos se pidió utiliar cinco distintas probabilidades para la probabilidad de que exista una arista, se utilizaron los siguientes valores

p
0,00005
0,0001
0,0005
0,001
0,05

Que para todo $n = 2^i$ con $i \in 10, 11, ..., 20$, p se encuentra en el intervalo $[1/n, 1]$ como se pidió.

2.2. Código

2.2.1. Main

En Main se obtendran los archivos donde se registrán los tiempos de creación de los grafo, la ejecucion de los tres algoritmos, además de la cantidad de vertices que cada algoritmo obtiene para poder cubrir el grafo, para luego poder graficar. Para esto se hizo lo siguiente.

- Primero se definen las variables a utilizar al iterar.
- Se itera sobre los valores de i, creando dos archivos, un archivo de texto para poder ser leido por una persona y otro en formato CSV para poder ser leido por un software para luego ser graficado.
- En cada iteración sobre i se hacen tres experimentos por cada valor de p.
- En cada uno de estos experimentos sobre un p, se genera un grafo aleaotrio midiendo su tiempo de contrucción y se crean dos copias de esta para que cada algoritmo trabaje con una copia (pudiendo cambiarla).Luego se ejecuta cada algoritmo midiendo sus tiempos de ejecucion y registrando la cantidad de vertices de su solución.

2.2.2. Vertex

Clase que representa un vértice de la estructura, posee un primer valor que representa donde empieza las aristas de este vértice y un ultimo que es donde terminan las aristas de este vértice en el arreglo de aristas.

2.2.3. Edge

Clase que representa una arista de la estructura,posee una fuente que representa una posición de donde comienza una arista y un blanco que representa el vertice donde termina la arista.

2.2.4. Graph

Representa al grafo, posee dos listas, una de vertices y otra de aristas.
Posee tres constructor y dos métodos auxiliares:

- Graph(int n, int m):Crea una grafo vacio, con aristas y vertices inicializados.
- Graph(Graph g):Crea una copia del grafo g.
- Graph(List¡Vertex¿vertices, List¡Edge¿edges):Crea un grafo a partir de dos listas, una de vertices otra de aristas.
- setFirstTo(int position, int first):Cambia el primer valor del vertice en la posicion *position*, por el valor *first*.
- setLastTo(int position, int last):Cambia el ultimo valor del vertice en la posicion *position*, por el valor *last*
- changeEdge(int position, int src, int tgt, int cmp): Cambia los valores de la edge en la posicion *position* del arreglo de aristas, con los valores entregados en el método.
- getVertexIn(int position): Entrega el vertice que se encuentra en esta posición en la lista de vértices.
- getEdgeIn(int position): Entrega la arista que se encuentra en esta posición en la lista de aristas.
- getE(): Entrega la lista de aristas.
- getV(): Entrega la lista de vértices.

2.2.5. GraphGenerator

Genera un grafo aleatorio.

- create(int n, double p): Se crea un grafo aleatorio de tamano n, con probabilida de que exista una arista de p. Las aristas son creadas aleatoriamente segun el enunciado, luego se les hace un post proceso.
- invert(List(List¡Edge¿) buckets): Toma un arreglo de aristas, las invierte y les asigna el indice en que se encontraban antes de la inversion.
- merge(ArrayList(ArrayList¡Edge¿) list): Junta ordena los buckets de aristas manteniendo los ordenes parciales.
- recMerge(ArrayList(ArrayList¡Edge¿) list1, ArrayList(ArrayList¡Edge¿) list2): Dada dos listas las junta, ordenando establemente por el primer valor.

2.2.6. TwoAproximation

Algoritmo de la 2-Aproximación.

- TwoAproximation(Graph g): Algoritmo de 2-Aproximacion, que itera mientres queden aristas. Se guarda la lista de vertices que es un cubrimiento en la variable vertexCover.
- getVertexCoverSize(): Retorna el tamaño de la solución.

2.2.7. MaximumDegreeHeuristic

Algoritmo de la Heuristica de grado mayor.

- MaximumDegreeHeuristic(Graph g): A partir de un grafo, se crea un cobertura con la Heurística de grado mayor.
- getVertexWithMaxDegree(List¡Vertex¿currentVertices,List¡Edge¿currentEdges): Metodo para obtener el vertice con mayor grado del grafo.
- getVertexCoverSize(): Retorna el tamaño de la solución.

2.2.8. ImprovedTwoAproximation

Algoritmo de la 2-Aproximación mejorada.

- ImprovedTwoAproximation(Graph g): Se obtiene un covertura de vertices a partir de un grafo, utilizando el algoritmo de 2-Aproximacion mejorado.
- getMaximumDegreeNeighbour(Vertex u, List¡Vertex¿currentVertices, List¡Edge¿currentEdges): Obtiene el vecino con mayor grado a partir de un vertice del grafo.
- getVertexCoverSize(): Retorna el tamaño de la solución.

2.2.9. Timer

Cronometro para medir los tiempos de construcción del grafo aleatorio, y los tiempos de ejecución de los algoritmos.

- start(): Comienza el cronómetro.
- stop(): Detiene el cronómetro, retorna el tiempo transcurrido en segundos.

2.2.10. FileManager

Este código pertenece al profesor José Fuentes Sepúlveda,fue traducido desde C.

- readGraphFromFile(String fileName): La funcion recibe un nombre de archivo y devuelve un objeto Graph con toda la informacion del archivo.

3. Presentación de los Resultados

3.1. Tiempo de Creación y Búsqueda del Suffix Array

Los resultados para los tiempos de construcción del Suffix Array, fueron los siguientes.

Tamaño del texto (Kb) (	Tiempo de Construcción (ms)
250	210,398
500	384,365
1000	562,266
2000	2345,070
4000	9040,519
8000	25547,724
16000	66096,574
32000	96510,139
64000	209359,431

Debido al mayor uso de memoria del Suffix Array en comparaión al Automata, no se pudieron realizar experimentos para textos más grandes.

Para el caso de la búsqueda de una palabra el texto, los resultados fueron los siguientes.

Tamaño del texto (Kb) (	Tiempo de Búsqueda (ms)
250	3,426
500	7,713
1000	16,271
2000	37,243
4000	104,214
8000	284,076
16000	513,799
32000	964,349
64000	1951,790

Se gráficaron estás dos tablas, los resultados son los siguientes.

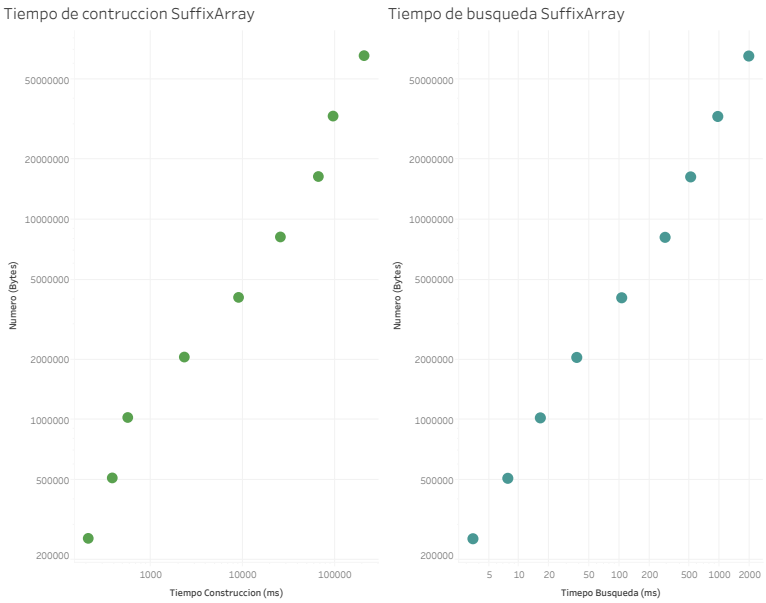

Figura 1: Gráficos del tiempo de creación y búsqueda en el Suffix Array.

3.2. Tiempo de Creación y Búsqueda del Automata

Los resultados para los tiempos de construcción del Automata, fueron los siguientes.

Tamaño del texto (Kb) (	Tiempo de Construcción (ms)
250	0,014
500	0,011
1000	0,011
2000	0.012
4000	0.102
8000	0.029
16000	0.013
32000	0.031
64000	0.013
128000	0.092
256000	0.011

Para el caso de la búsqueda de una palabra el texto, los resultados fueron los siguientes.

Tamaño del texto (Kb) (	Tiempo de Búsqueda (ms)
250	3,199
500	5,909
1000	12,521
2000	25,595
4000	45,360
8000	117,171
16000	215,554
32000	776,584
64000	664,720
128000	1150,971
256000	2774,850

Se gráficaron estás dos tablas, los resultados son los siguientes.

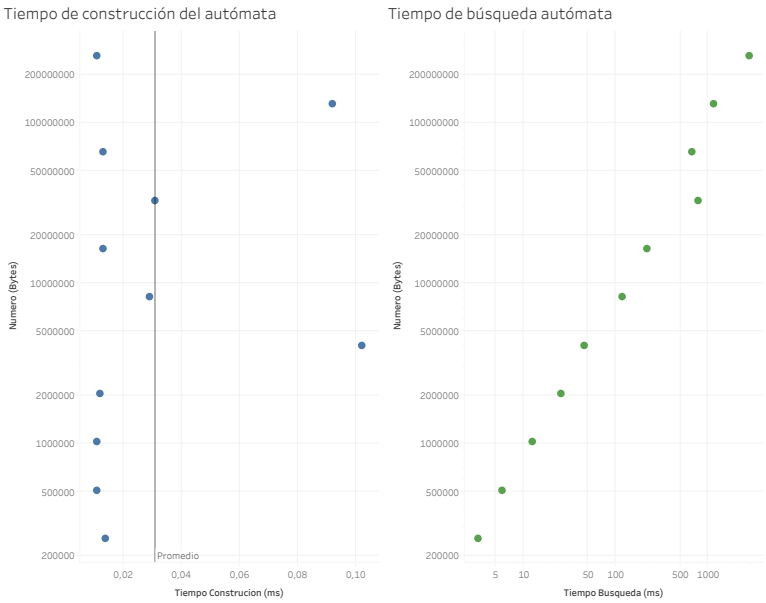

Figura 2: Gráficos del tiempo de creación y búsqueda en el Automata.

4. Análisis y Conclusiones

4.1. Construcción del Suffix Array

Se observa del gráfico obtenido para la construcció que la implementación de la construcción del Suffix Array crece linealmente con el tamaño del texto, lo cual coincide con la hipótesis presentada al inicio del informe.

4.2. Búsqueda en el Suffix Array

Se observa del gráfico de la búsqueda del Suffix Array que el tiempo crece linealmente con el tamaño del texto, lo cual no coincide con la hipótesis que se habia presentado, revisando el código se realizó la tranformación de cada sufijo a un arreglo de *char* lo que toma $O(n)$, es por esto que se obtuvieron estos resultados.

4.3. Construcción del Automata

El grafico de la construcción del Automata no puede ser analisado debido a que no fueron registrados los largos del patrón, solo puede observarse que los tiempos de ejecución son muy pequeños.

4.4. Búsqueda en el Automata

Se observa del gráfico que la búsqueda de una palabra en el texto usando el algoritmo del Automata, que el tiempo crece linealmente con el tamaño del texto, lo cual coincide con la hipótesis que se habia presentado.

4.5. Conclusiones

La construcción del Suffix Array resultó igual al orden teórico que se conocia, para el caso del la búsqueda en él, se obtuvieron malos resultados debido a una mala implementación, debido a que en un paso del algoritmo se realizó un paso innecesario de la transformación de un *String* a un arreglo de *char* el cual hace que el timepo aumnete linealmente con la entrada, se corrigió este problema y se corrieron un número pequeños de experimentos (Anexo 1), en los cuales se podía observar la mejora del tiempo de búsqueda del algoritmo, pero al ser tan pocos experimentos no es concluyente.
Para la construcción del Automata se realizaron de manera incorrecta los experimentos debido a que no se midió el largo del patron, se deberian haber repetido los experimentos, pero debido que el momento en que se detecto esta falla se estaba muy cerca de la fecha de entrega ya no quedaba tiempo para realizar un número suficiente de experimentos para obtener resultados convincentes. Aunque no se puede comparar el orden del algoritmo de construcción del Automata, si se puede observar que los tiempos de construcción en general fueron muy pequeños. La búsqueda en el Automata resultó del mismo orden del algoritmo teórico.

Estas dos implementaciones funcionan para distintos propositos, el enfoque del Suffix Array tiene un orden lineal para construirse, pero posee un tiempo menor para la busqueda en el arreglo, por lo que debería ser usado en el caso de hacer muchas consultas sobre un texto. En el caso del Automata, la construcción toma muy poco tiempo pero correrlo sobre el texto es lineal al tamaño del texto, por lo que este enfoque puede ser usado cuando se quiere hacer pocas consultas sobre el texto.